

# FPS-loss relation to mutual information

Kirill Tyshchuk

March 2021

Рассмотрим первую строку в матрице, к которой мы применяем FPS-loss. Пусть переменная  $z$  соответствует строке, и ей соответствует один позитивный пример  $x$  из столбцов и  $N - 1$  негативных примеров  $x_i^{neg}$ .

Пусть  $f(x, z)$  обозначает выход нашей модели (включая экспоненту из Softmax):

$$f(x, z) = \exp(\langle \text{embed}(x), \text{embed}(z) \rangle)$$

Распишем матожидание вклада этой строки в минус FPS-loss, то есть кросс-энтропии с таргетом  $(1, 0, \dots, 0)$ :

$$-\mathbb{E}\mathcal{L}_{row} = -\mathbb{E} \left[ \log \frac{f(x, z)}{f(x, z) + \sum_{i=1}^{N-1} f(x_i^{negative}, z)} \right] = \quad (1)$$

$$= \mathbb{E} \log f(x, z) - \mathbb{E} \log(f(x, z) + \sum_{i=1}^{N-1} f(x_i^{negative}, z)) \leq \quad (2)$$

$$\leq \mathbb{E} \log f(x, z) - \mathbb{E} \log(\sum_{i=1}^{N-1} f(x_i^{negative}, z)) \approx \quad (3)$$

$$\approx \mathbb{E} \log f(x, z) - \log(\mathbb{E} f(x^{neg}, z)) - \log(N - 1) = \quad (4)$$

$$= \mathbb{E} \log \frac{f(x, z)}{\mathbb{E} f(x^{neg}, z)} - \log(N - 1) \quad (5)$$

Если у нас нет каких-то сложных негативов, то здесь фигурируют два распределения: пара с позитивным примером  $(x, z)$  берётся из совместного распределения  $\mathbb{P}_{XZ}$ , а пары с негативным  $(x^{neg}, z)$  берутся из произведения маргинальных распределений  $\mathbb{P}_X \otimes \mathbb{P}_Z$  (взяли  $z$  и случайный  $x$ , не обязательно относящийся к делу). KL-дивергенция между этими распределениями равна взаимной информации между  $X$  и  $Z$ :

$$I(X, Z) = D_{KL}(\mathbb{P}_{XZ} || \mathbb{P}_X \otimes \mathbb{P}_Z) = \mathbb{E}_{\mathbb{P}_{XZ}} \frac{d\mathbb{P}_{XZ}}{d\mathbb{P}_X \otimes \mathbb{P}_Z}$$

Введём третье распределение  $\mathbb{G}$ :

$$d\mathbb{G}(x, z) \propto f(x, z)p(x)p(z) = f(x, z)d\mathbb{P}_X \otimes \mathbb{P}_Z$$

Нормировочная константа как раз равна

$$C_f = \iint f(x, z)p(x)p(z)dx dz = \mathbb{E}_{\mathbb{P}_X \otimes \mathbb{P}_Z} f(x, z) = \mathbb{E}f(x^{neg}, z)$$

Распишем выражение из (5) в терминах взаимной информации и распределения  $\mathbb{G}$ :

$$\mathbb{E} \log \frac{f(x, z)}{\mathbb{E}f(x^{neg}, z)} = \mathbb{E} \log \frac{d\mathbb{G}}{d\mathbb{P}_X \otimes \mathbb{P}_Z} = \quad (6)$$

$$= \mathbb{E} \log \frac{d\mathbb{P}_{XZ}}{d\mathbb{P}_X \otimes \mathbb{P}_Z} - \mathbb{E} \log \frac{d\mathbb{P}_{XZ}}{d\mathbb{G}} = \quad (7)$$

$$= D_{KL}(\mathbb{P}_{XZ} || \mathbb{P}_X \otimes \mathbb{P}_Z) - D_{KL}(\mathbb{P}_{XZ} || \mathbb{G}) = \quad (8)$$

$$= I(X, Z) - D_{KL}(\mathbb{P}_{XZ} || \mathbb{G}) \leq I(X, Z) \quad (9)$$

Собирая всё в кучу, получаем, что минус FPS-loss по всем  $N$  строкам имеет матожидание

$$-\mathbb{E}\mathcal{L}_{row} \approx N(I(X, Z) - D_{KL}(\mathbb{P}_{XZ} || \mathbb{G}) - \log(N-1))$$

Кроме того, оптимум достигается при

$$d\mathbb{G} = d\mathbb{P}_{XZ} \iff f(x, z) \propto \frac{p(x, z)}{p(x)p(z)} = \exp(PMI(x, z))$$

Выкладки получены адаптацией рассуждений из статьи об InfoNCE[2] и аппендикса из статьи о MINE[1]. В аппендиксе статьи об InfoNCE связь со взаимной информацией получена немного по-другому.

## Список литературы

- [1] Mohamed Ishmael Belghazi, Aristide Baratin, Sai Rajeswar, Sherjil Ozair, Yoshua Bengio, Aaron Courville, and R Devon Hjelm. MINE: Mutual Information Neural Estimation. *arXiv e-prints*, page arXiv:1801.04062, January 2018.
- [2] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation Learning with Contrastive Predictive Coding. *arXiv e-prints*, page arXiv:1807.03748, July 2018.